

PENERAPAN SISTEM INFERENSI MAMDANI DALAM ANALISIS SENTIMEN DENGAN VADER LEXICON INSET PADA DATASET SENTIMEN MBG

Antony Vincent Siagian¹, Aditya Pratama Juliyawan², daffa Syauqi Raihan³
Aziz Nurhidayat Adriyanto⁴

e-mail: antonyvincent8867@students.unnes.ac.id, adityajuliyawan@students.unnes.ac.id,
daffasyauqi2705@students.unnes.ac.id, aziznurhidayat42132@students.unnes.ac.id

Abstract

Analisis sentimen pada berita ekonomi berbahasa Indonesia masih terkendala oleh keterbatasan lexicon dalam menangkap nuansa dan ambiguitas teks. Penelitian ini menerapkan sistem inferensi Mamdani untuk mengklasifikasikan sentimen berita MBG melalui integrasi VADER dan InSet Lexicon. Tahapan penelitian meliputi web scraping, preprocessing, perhitungan skor sentimen, fuzzifikasi, perancangan rule base, inferensi Mamdani, dan defuzzifikasi. Hasil evaluasi menunjukkan performa yang belum optimal dengan F1-Micro 0.51 dan F1-Macro 0.31, terutama karena kelemahan InSet Lexicon yang menghasilkan skor polaritas lemah dan kurang mampu mengaktifkan aturan fuzzy secara efektif. Meski demikian, sistem Mamdani tetap mampu memberikan keputusan sentimen yang lebih gradual dan interpretatif. Penelitian ini menegaskan pentingnya pengembangan lexicon khusus domain ekonomi serta penyempurnaan aturan fuzzy untuk meningkatkan akurasi analisis sentimen Indonesia.

Keywords: *Sentiment Analysis, InSet Lexicon, VADER, Fuzzy Logic, Mamdani Inference System, Rule-Based Classification*

1. INTRODUCTION

Perkembangan analisis sentimen dalam beberapa tahun terakhir menunjukkan peran pentingnya dalam memahami persepsi publik terhadap isu-isu ekonomi, kebijakan, maupun aktivitas korporasi. Di Indonesia, pergerakan opini publik terhadap entitas pasar dan bisnis semakin sering diamati melalui data digital, termasuk pemberitaan dan percakapan media sosial. Salah satu topik yang relevan adalah sentimen publik terhadap dinamika pemberitaan terkait MBG, yang menjadi sorotan karena keterkaitannya dengan aktivitas korporasi, regulasi keuangan, serta kinerjanya dalam pasar domestik. Analisis sentimen diperlukan untuk mengidentifikasi kecenderungan opini masyarakat, terutama karena teks berita sering kali mengandung bahasa yang ambigu, bernuansa netral, atau memiliki makna implisit yang sulit ditangkap oleh model berbasis kata kunci sederhana.

Masalah utama dalam analisis sentimen pada teks berita berbahasa Indonesia terletak pada keterbatasan metode berbasis lexicon konvensional. Meskipun metode lexicon seperti VADER dan InSet umum digunakan, pendekatan ini tidak selalu mampu menangkap nuansa linguistik, variasi diksi, ataupun intensitas emosi dalam kalimat yang kompleks. Selain itu, pemberitaan ekonomi sering bersifat informatif dan minim ekspresi polaritas secara eksplisit, sehingga pendekatan biner positif-negatif menjadi kurang memadai. Ketidakpastian makna dan tumpang tindih antar polaritas menuntut teknik yang mampu menangani ambiguitas, seperti logika fuzzy. Hal ini juga ditegaskan dalam sebuah penelitian yang menunjukkan bahwa penggunaan satu lexicon saja sering menghasilkan penurunan akurasi pada teks dengan intensitas emosi yang tidak tegas [1].

Pendekatan fuzzy rule-based menawarkan solusi terhadap permasalahan tersebut melalui kemampuan memetakan polaritas sentimen secara gradual alih-alih kategorikal. Dibandingkan metode klasik, fuzzy rule-based mengizinkan nilai sentimen berada pada spektrum kontinu dan menggabungkan berbagai indikator melalui aturan linguistik yang interpretatif. Studi menunjukkan bahwa pendekatan fuzzy mampu mengatasi ambiguitas

sentimen publik terhadap kebijakan ekonomi nasional, dengan kinerja lebih baik dibandingkan SVM dan Naïve Bayes [2].

State of the art analisis sentimen menunjukkan bahwa integrasi lexicon dan fuzzy inference memberikan model yang lebih adaptif terhadap variasi bahasa dan konteks, terutama pada teks non-linear seperti berita ekonomi. Selain itu, penggunaan InSet Lexicon memberikan fondasi yang lebih sesuai bagi teks berbahasa Indonesia, sedangkan VADER menawarkan struktur heuristik yang kuat dalam menangkap intensitas polaritas. Dengan menggabungkan keduanya, proses analisis dapat menghasilkan skor polaritas yang lebih stabil sebelum masuk ke tahapan inferensi Mamdani. Metode Mamdani dipilih karena kemampuannya memodelkan penalaran linguistik melalui aturan IF-THEN yang dapat disesuaikan dengan konteks domain, serta karena sifatnya yang interpretatif sehingga cocok untuk analisis berbasis kebijakan [3]

Penelitian ini mengusulkan alur analisis sentimen komprehensif yang meliputi: web scraping data MBG dari portal berita, pembersihan dan preprocessing teks, klasifikasi sentimen awal menggunakan InSet Lexicon, integrasi lexicon Indonesia dengan VADER, fuzzifikasi skor positif-negatif-netral, perancangan rule base linguistik, penerapan sistem inferensi Mamdani, defuzzifikasi untuk memperoleh nilai crisp, serta evaluasi kinerja model. Pendekatan ini diharapkan dapat memberikan hasil yang lebih stabil dibandingkan klasifikasi lexicon murni, sekaligus menawarkan interpretasi sentimen yang lebih selaras dengan karakteristik teks berita ekonomi.

Dengan demikian, tujuan utama penelitian ini adalah menerapkan sistem inferensi Mamdani berbasis fuzzy rule terhadap skor sentimen hasil integrasi VADER dan InSet Lexicon untuk mengklasifikasikan sentimen pada dataset berita MBG di Indonesia secara lebih akurat, adaptif, dan interpretatif. Selain menghasilkan model yang lebih robust dalam menangani ambiguitas, penelitian ini juga berkontribusi pada pengembangan metode analisis sentimen berbahasa Indonesia yang menggabungkan kekuatan lexicon dan fuzzy reasoning.

2. RESEARCH METHOD

Dataset yang digunakan dalam penelitian ini merupakan *sentiment news dataset* terkait kata kunci “MBG” yang diperoleh melalui proses *web scraping* dari portal berita CNBC.com. Pemilihan CNBC.com sebagai sumber data didasarkan pada reputasinya sebagai salah satu media ekonomi dan bisnis yang kredibel, serta konsistensi publikasi berita terkait aktivitas pasar, korporasi, dan kebijakan yang relevan dengan analisis sentimen.

Pengumpulan data dilakukan dalam rentang waktu 1 Januari 2023 hingga 12 November 2025. Rentang waktu ini dipilih untuk memastikan cakupan data yang memadai terkait dinamika pemberitaan MBG dalam kurun waktu lebih dari dua tahun, sehingga variasi sentimen positif, negatif, maupun netral dapat dianalisis secara lebih komprehensif.

Dataset hasil scraping terdiri dari empat fitur utama, yaitu tanggal, URL berita, judul, dan isi artikel. Fitur tanggal berisi informasi mengenai waktu publikasi berita, sehingga memungkinkan analisis perubahan sentimen dari waktu ke waktu sekaligus memudahkan penyelarasan dengan data eksternal apabila diperlukan. Fitur URL berita menyimpan tautan asli menuju artikel di CNBC.com dan berfungsi sebagai identitas dokumen yang berguna untuk verifikasi maupun penelusuran ulang. Judul berita digunakan sebagai ringkasan awal konten, karena sering kali mengandung indikasi sentimen yang jelas dan relevan sebagai

bahan analisis. Sementara itu, fitur isi artikel merupakan konten lengkap dari berita dan menjadi sumber utama dalam proses pengolahan teks, meliputi pembersihan, normalisasi, tokenisasi, dan tahapan lain sebelum digunakan dalam proses klasifikasi sentimen.

2.1 Logika Fuzzy

Logika Fuzzy (*Fuzzy Logic*) adalah suatu bentuk logika yang mengenalkan konsep kebenaran sebagian (*partial truth*). Berbeda dengan logika klasik (*Boolean*) yang hanya mengenal dua nilai mutlak yaitu 0 (*salah/false*) atau 1 (*benar/true*), logika fuzzy memungkinkan nilai kebenaran berada dalam rentang kontinu antara 0 dan 1.

Logika fuzzy diperkenalkan oleh Dr. Lotfi Zadeh dari Universitas California, Berkeley pada tahun 1965. Konsep *fuzzy sets* menurut Zadeh (1965) adalah sebagai suatu kerangka matematis untuk merepresentasikan ketidakpastian yang timbul akibat ketidaktegasan makna atau batasan suatu konsep. Tidak seperti himpunan klasik (*crisp set*) yang membagi elemen hanya ke dalam dua kategori biner “anggota” atau “bukan anggota”, fuzzy set memungkinkan derajat keanggotaan yang bersifat kontinu pada interval $[0,1]$. Jika suatu fuzzy set A didefinisikan pada semesta pembicaraan X , maka untuk setiap elemen $x \in X$, terdapat fungsi keanggotaan $\mu_A(x)$ yang menyatakan sejauh mana x memenuhi karakteristik dari konsep yang diwakili oleh A . Nilai 0 berarti elemen tersebut sama sekali tidak menjadi anggota, nilai 1 menunjukkan keanggotaan penuh, sedangkan nilai antara 0 dan 1 mencerminkan keanggotaan parsial. Representasi kontinu ini memberi kemampuan bagi fuzzy set untuk memodelkan konsep linguistik seperti “tinggi”, “hangat”, “sedikit jauh”, atau “cukup besar”, yang secara alami tidak memiliki batas yang tegas [4].

Operasi dasar pada fuzzy set secara langsung diturunkan dari fungsi keanggotaannya. Komplemen suatu fuzzy set A dirumuskan sebagai $\mu_{A'}(x) = 1 - \mu_A(x)$. Operasi irisan didefinisikan dengan mengambil nilai minimum dari dua derajat keanggotaan, yaitu $\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$. Sebaliknya, operasi gabungan ditentukan oleh nilai maksimum dari dua fungsi keanggotaan, yaitu $\mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$. Ketiga operasi ini membentuk dasar aljabar fuzzy dan secara langsung menggeneralisasi operasi-operasi himpunan klasik. Zadeh juga memperkenalkan operasi tambahan, seperti *algebraic product* ($\mu_{A \cdot B}(x) = \mu_A(x)\mu_B(x)$) dan *algebraic sum* ($\mu_{A+B}(x) = \mu_A(x) + \mu_B(x)$) (dengan batasan jumlah tidak melebihi 1). Operasi-operasi tersebut memberikan alternatif yang lebih fleksibel dalam menggabungkan dan memodifikasi fuzzy set, terutama dalam aplikasi yang membutuhkan representasi nonlinear dari interaksi dua variabel fuzzy.

Selain operasi himpunan, terdapat konsep fuzzy yaitu relasi fuzzy. Relasi fuzzy pada $X \times Y$ direpresentasikan melalui fungsi keanggotaan dua variabel $\mu_R(x, y)$. Komposisi antara dua relasi fuzzy A dan B , yang dilambangkan sebagai $B \circ A$, didefinisikan melalui operator sup–min:

$$\mu_{B \circ A}(x, y) = \sup_{v \in X} \min\{\mu_A(x, v), \mu_B(v, y)\}.$$

Komposisi ini bersifat asosiatif dan menjadi dasar bagi inferensi fuzzy serta berbagai aplikasi seperti kontrol fuzzy dan sistem rekomendasi berbasis aturan. Zadeh juga meninjau relasi fuzzy yang diinduksi oleh pemetaan $T: X \rightarrow Y$. Jika fuzzy set A di X diproyeksikan ke Y , fungsi keanggotaan pada ruang baru diperoleh melalui nilai supremum, yaitu $\mu_B(y) =$

$\sup\{\mu_A(x) \mid T(x) = y\}$. Prosedur ini penting dalam transformasi data atau proses pemodelan di mana variabel fuzzy mengalami perubahan domain.

Lalu, terdapat juga konsep-konsep penting seperti *alpha-cut*, yaitu himpunan crisp yang diperoleh dari fuzzy set dengan mengambil seluruh elemen yang memiliki keanggotaan minimal α . Dengan pendekatan ini, konveksitas fuzzy set dapat didefinisikan secara analog dengan konveksitas pada ruang Euclidean: fuzzy set dikatakan konveks apabila setiap α -cut untuk $\alpha \in (0,1]$ merupakan himpunan konveks. Konsep ini relevan dalam bidang optimisasi, pengenalan pola, dan pemodelan geometri fuzzy karena memberikan jaminan bentuk terstruktur dan tidak terpisah-pisah pada fuzzy set.

Zadeh juga merumuskan *separation theorem* untuk fuzzy convex sets. Teorema ini menyatakan bahwa dua fuzzy set yang konveks dan terbatas memiliki derajat pemisahan linear maksimum yang dapat ditentukan dari nilai supremum irisan fuzzy-nya. Jika $M = \sup_x \min\{\mu_A(x), \mu_B(x)\}$, maka derajat pemisahan terbaik yang dapat dicapai adalah $D = 1 - M$. Artinya, meskipun dua fuzzy set mungkin saling tumpang tindih, masih memungkinkan untuk menentukan hyperplane yang memisahkan keduanya sampai derajat tertentu. Teorema ini menjadi dasar teori dalam klasifikasi fuzzy dan diskriminasi pola berbasis fungsi linear

2.2 Fuzzifikasi

Fuzzifikasi merupakan proses awal dalam sistem logika fuzzy yang berfungsi mengubah nilai crisp atau nilai numerik menjadi representasi fuzzy dalam bentuk derajat keanggotaan (membership degree). Konsep ini pertama kali diperkenalkan oleh Zadeh (1965), yang menjelaskan bahwa sebuah nilai tidak harus tegas berada dalam satu himpunan, tetapi dapat memiliki tingkat keanggotaan antara 0 hingga 1 pada beberapa himpunan fuzzy sekaligus. Proses fuzzifikasi dilakukan dengan memetakan input ke dalam fungsi keanggotaan seperti segitiga, trapesium, atau Gaussian, yang digunakan untuk menggambarkan konsep linguistik seperti “rendah”, “sedang”, atau “tinggi” [5]. Fuzzifikasi memungkinkan sistem untuk menangani data yang mengandung ambiguitas, ketidakpastian, dan variabilitas yang sulit direpresentasikan menggunakan logika biner [6].

Analisis sentimen dibangun dengan tiga variabel utama: positif, negatif, dan netral. Masing-masing variabel ini mewakili kecenderungan emosi dari suatu teks atau data numerik. Nilai input awal biasanya berupa angka antara 0 sampai 1, tetapi interpretasinya masih kasar. Oleh karena itu, setiap variabel input (positif, negatif, netral) direpresentasikan sebagai sebuah domain nilai kontinu:

$$x \in [0,1]$$

Setiap variabel (positif, negatif, netral) dibagi menjadi tiga membership set:

1. Low (rendah)
2. Mid (sedang)
3. High (tinggi)

Secara matematis, tiap tingkat adalah sebuah *membership function* atau fungsi keanggotaan:

$$\mu_{\text{low}}(x), \mu_{\text{mid}}(x), \mu_{\text{high}}(x)$$

Penelitian terdahulu, proses fuzzifikasi pada profil MMPI berperan penting karena memungkinkan rentang nilai skala direpresentasikan sebagai himpunan fuzzy yang dapat dipakai langsung oleh algoritma klasifikasi berbasis fuzzy, data yang telah difuzzifikasi ini menjadi masukan utama bagi proses evaluasi aturan atau pembentukan model fuzzy [7]. Dengan demikian, fuzzifikasi menjadi komponen penting yang menghubungkan data mentah dengan proses penalaran fuzzy yang lebih kompleks, sebelum akhirnya ditransformasikan kembali menjadi nilai crisp melalui tahapan defuzzifikasi.

2.3 Metode Rule-Based untuk Klasifikasi Sentimen

Pendekatan rule-based dalam penelitian ini dirancang untuk mengelompokkan dokumen ke dalam kategori sentimen *positif*, *negatif*, dan *netral* berdasarkan interaksi antara indikator sentimen positif, negatif, dan netral yang diperoleh dari analisis leksikal. Metode ini mengacu pada prinsip inferensi linguistik yang menekankan interpretabilitas aturan serta kemampuan menangani ketidakpastian teks.

Perancangan Rule Base

Penyusunan rule base dilakukan dengan mempertimbangkan tiga variabel masukan: kecenderungan positif, kecenderungan negatif, dan tingkat netralitas dokumen. Setiap variabel dibagi ke dalam tiga kategori linguistik (*low*, *mid*, *high*) untuk merepresentasikan intensitas indikasi sentimen. Berdasarkan karakteristik distribusi nilai dan interaksi antarvariabel, aturan klasifikasi dirancang untuk mencerminkan tiga prinsip utama:

Penetapan aturan klasifikasi sentimen dalam penelitian ini didasarkan pada tiga prinsip utama yang memastikan sistem rule-based bekerja secara konsisten dan interpretatif. Prinsip pertama adalah penetapan kelas positif dan negatif secara ketat, di mana dokumen langsung diklasifikasikan ke dalam kategori sentimen ekstrem apabila salah satu polaritas positif atau negatif menunjukkan dominasi yang jelas sementara polaritas lainnya berada pada tingkat rendah [8].


Implementasi Rule Base dalam Sistem

Rule base diimplementasikan dalam bentuk serangkaian pernyataan IF-THEN yang mengaitkan kondisi antecedent dengan keputusan sentimen. Aturan berikut diadopsi secara langsung sebagai basis keputusan utama, sebagaimana tercantum dalam sel kode sistem:

Tabel 1. Sistem Rule Base Mamdani

Kategori Aturan	Kondisi Antecedent	Output Sentimen	Deskripsi
Positif (ketat)	Pos tinggi $\wedge$ Neg rendah $\wedge$ Neu rendah	Positive	Polaritas positif dominan $\rightarrow$ sentimen positif eksplisit
	Pos sedang $\wedge$ Neg rendah $\wedge$ Neu rendah	Positive	Positif moderat tanpa gangguan negatif
Negatif (ketat)	Neg tinggi $\wedge$ Pos rendah $\wedge$ Neu rendah	Negative	Polaritas negatif mendominasi $\rightarrow$ sentimen negatif kuat

	Neg sedang $\wedge$ Pos rendah $\wedge$ Neu rendah	Negative	Negatif moderat sebagai indikator utama
Netral (prioritas)	Netral tinggi	Neutral	Indikasi kuat bahwa teks bersifat informatif/ambiguous
	Netral sedang	Neutral	Tidak ada dominasi polaritas $\rightarrow$ tetap netral
	Pos sedang $\wedge$ Neg sedang	Neutral	Kedua polaritas seimbang $\rightarrow$ keputusan netral
	Pos rendah $\wedge$ Neg rendah	Neutral	Tidak ada indikasi polaritas $\rightarrow$ teks informatif



Gambar 1. Diagram Alir Rule Based

Prinsip kedua adalah pemberian prioritas pada kelas netral, khususnya ketika nilai positif dan negatif tampak seimbang atau ketika indikasi netralitas muncul dalam intensitas sedang hingga tinggi. Kasus seperti ini umum ditemukan pada teks berita, yang sering bersifat informatif atau ambigu. Prinsip ketiga adalah robustness terhadap variasi skor, di mana aturan dirancang untuk tetap stabil dan konsisten pada berbagai rentang intensitas sentimen baik rendah, sedang, maupun tinggi. Hal ini penting mengingat variasi ekspresi linguistik pada teks berita dapat sangat luas. Keselarasan prinsip ini dengan literatur rule-based modern yang menunjukkan bahwa interpretabilitas dan generalisasi aturan merupakan elemen penting untuk memastikan metode rule-based dapat diterapkan pada berbagai konteks tanpa kehilangan konsistensi [9].

2.4 Sistem Inferensi Fuzzy

Struktur dasar *fuzzy inference system* (FIS) umumnya terdiri atas tiga elemen utama, yaitu: (1) *Rule Base*, (2) *Database*, dan (3) mekanisme inferensi. *Rule Base* memuat kumpulan aturan logika *if-then* yang dirancang oleh pengguna untuk menggambarkan hubungan antara variabel input dan output. *Database* menyimpan definisi fungsi keanggotaan yang digunakan untuk merepresentasikan setiap variabel fuzzy, baik pada sisi input maupun output. Sementara itu, mekanisme inferensi bertugas mengolah input berdasarkan aturan dan fungsi keanggotaan tersebut sehingga menghasilkan keluaran yang sesuai dengan logika fuzzy. Kedua metode ini memiliki tahapan kerja yang mirip dalam hal proses fuzzifikasi, penerapan aturan, dan inferensi. Perbedaannya terletak pada bentuk output yang dihasilkan: sistem Mamdani menghasilkan keluaran dalam bentuk himpunan fuzzy yang kemudian perlu melalui proses defuzzifikasi, sedangkan sistem Sugeno menghasilkan keluaran berupa fungsi linear atau konstanta, sehingga proses perhitungan outputnya cenderung lebih sederhana dan efisien [10].

Metode Mamdani sering dikenal sebagai metode Max-Min, diperkenalkan oleh Embrahim Mamdani seperti yang ditemukan Dr. Lotfi Zadeh pada tahun 1965. Sistem inferensi fuzzy ini terdiri dari 4 fase [11]. Pada sistem inferensi fuzzy Mamdani, apabila terdapat dua variabel masukan, yaitu x dan y , serta satu variabel keluaran z , maka bentuk aturannya adalah:

Jika x memiliki nilai a dan y memiliki nilai b , maka/then z bernilai c , di mana a , b , dan c merupakan angka real. Bagian “jika/if” disebut *antecedent*, sedangkan bagian “maka/then” disebut *consequent*. Saat sebuah nilai umumnya berupa nilai *crisp* dimasukkan ke dalam FIS, nilai tersebut terlebih dahulu melalui proses *fuzzifikasi* menggunakan fungsi keanggotaan yang telah ditetapkan oleh pengguna. Fungsi keanggotaan ini biasanya digambarkan dengan label linguistik seperti Rendah, Sedang, Tinggi, dan lainnya. Nilai-nilai numerik yang telah dikonversi tersebut kemudian dipetakan menjadi bilangan fuzzy. Setelah itu, input fuzzy tersebut diproses oleh mesin inferensi fuzzy untuk menghasilkan output fuzzy.

Dalam FIS, terdapat dua jenis operator yang digunakan, yaitu “AND” dan “OR”. Kedua operator ini dapat didefinisikan dengan berbagai cara. Pada konteks ini, operator “OR” dan “AND” bekerja berdasarkan persamaan berikut:

$$\mu_{A \cup B}(x) = \max\{\mu_A(x), \mu_B(x)\}$$

$$\mu_{A \cap B}(x) = \min\{\mu_A(x), \mu_B(x)\}$$

Output fuzzy selanjutnya dikonversi kembali menjadi nilai *crisp* melalui tahap *defuzzifikasi*. Proses ini dapat dilakukan dengan berbagai pendekatan, seperti *center of gravity (COG)*, *bisector of area*, dan metode lainnya. Metode yang paling sering digunakan adalah metode *Centroid*. Pada metode centroid, solusi *crisp* diperoleh dengan mengambil titik pusat dari area fuzzy. Jika Z adalah hasil defuzzifikasi dari himpunan fuzzy S , maka:

$$\bar{z} = \frac{\int x \mu_S(x) dx}{\int \mu_S(x) dx}$$

di mana $\bar{z}$ merepresentasikan nilai keluaran akhirnya, sedangkan $\mu_s(x)$ menunjukkan fungsi keanggotaan dari variabel masukan.

2.5 Defuzzifikasi

Defuzzifikasi merupakan tahap akhir dalam sistem logika fuzzy yang berfungsi mengubah keluaran fuzzy menjadi nilai crisp yang dapat dipahami sebagai keputusan atau rekomendasi final. Karena proses inferensi fuzzy menghasilkan keluaran dalam bentuk himpunan fuzzy, dibutuhkan mekanisme untuk mengkonversinya kembali ke nilai tunggal agar dapat digunakan dalam aplikasi nyata. Defuzzifikasi adalah proses esensial yang memetakan distribusi keanggotaan fuzzy ke dalam nilai tegas melalui berbagai metode seperti centroid, bisector, mean of maxima, atau largest of maxima. Metode centroid merupakan pendekatan yang paling banyak digunakan karena mampu mewakili keseluruhan distribusi keluaran fuzzy secara proporsional. Selain itu, pemilihan metode defuzzifikasi dapat mempengaruhi performa sistem secara signifikan, terutama pada model yang memiliki aturan kompleks atau distribusi keanggotaan yang tidak simetris [12]. Dalam konteks analisis sentimen, defuzzifikasi menghasilkan nilai akhir sentimen dalam bentuk skala atau kategori tertentu (misalnya negatif, netral, atau positif), sehingga hasil inferensi fuzzy dapat disampaikan dalam bentuk yang mudah dianalisis maupun diinterpretasikan.

2.6 Metode Inset Lexicon untuk Analisis Sentimen Berbahasa Indonesia

Pendekatan inset lexicon digunakan untuk menyesuaikan VADER yang awalnya dikembangkan untuk bahasa Inggris agar mampu menganalisis teks berita berbahasa Indonesia. Adaptasi dilakukan dengan menambahkan kamus kata positif dan negatif berbahasa Indonesia ke dalam lexicon internal VADER. Metode ini selaras dengan praktik *domain adaptation* pada analisis sentimen berbasis kamus, di mana lexicon dimodifikasi agar mendukung konteks spesifik bahasa maupun domain tertentu [13].

Alur Proses Inset Lexicon

Tabel berikut merangkum tahapan utama inset lexicon dari data mentah hingga skor polaritas:

Tabel 2. Alur InSet Lexicon

Tahap	Proses	Output	Keterangan
1. Load Lexicon Indonesia	Membaca file positive.tsv dan negative.tsv	DataFrame lexicon gabungan	Berisi kata dan bobot polaritas
2. Scaling Bobot	Mengalikan bobot $\times 4$	Nilai polaritas baru	Menyesuaikan magnitudo agar mirip lexicon VADER (Hutto & Gilbert, 2014)

3. Konversi ke Format VADER	Mengubah DataFrame ke Kamus	lexicon_dict	Format kompatibel untuk analyzer.lexicon.update()
4. Inset ke VADER	Memperbarui lexicon internal VADER	VADER + Lexicon Bahasa Indonesia	Analyzer siap digunakan
5. Perhitungan Skor	polarity_scores(Article)	neg, neu, pos, compound	Digunakan sebagai dasar analisis sentimen

Pendekatan ini memastikan bahwa setiap artikel diproses dengan mempertimbangkan kosakata Bahasa Indonesia yang relevan dengan domain berita ekonomi.

Struktur Lexicon dan Formula Adaptasi

Setiap entri lexicon dibentuk melalui struktur dasar berikut:

Tabel 3. Struktur Dasar Indonesian Inset Lexicon

Kolom	Isi	Contoh
word	Kata dasar Indonesia	“anjlok”, “membaik”, “stabil”
weight	Bobot polaritas asli dari file TSV	-2, +1, +0.5
scaled_weight	$\text{weight} \times 4$	-8, +4, +2

Formula scaling yang digunakan:

$$\text{scaled_weight} = \text{original_weight} \times 4$$

Penguatan bobot ini dilakukan untuk menyesuaikan rentang polaritas lexicon Indonesia dengan rentang skor VADER, sehingga sensitivitas analisis meningkat.

Integrasi Lexicon ke VADER

Lexicon yang telah disesuaikan kemudian dimasukkan ke VADER menggunakan perintah:

```
analyzer.lexicon.update(lexicon_dict)
```

Proses ini menyebabkan setiap kata Indonesia yang muncul dalam artikel diberi skor polaritas tambahan atau pengganti apabila sudah ada entri sebelumnya dalam lexicon asli. Dengan demikian, sistem sentimen menjadi *bilingual* namun teroptimasi untuk Bahasa Indonesia.

Tabel 4. Integrasi Lexicon

Kata	Bobot Baru	Peran dalam Analisis
anjlok	-8	Memicu skor negatif tinggi
meningkat	+4	Menambah skor positif
stabil	+2	Memperkuat netral/positif ringan

Studi-studi sebelumnya menunjukkan bahwa memasukkan lexicon lokal meningkatkan kinerja model secara signifikan, terutama dalam konteks bahasa non-Inggris [14]. Penghitungan Skor Sentimen Skor polaritas dihitung menggunakan VADER dengan struktur keluaran sebagai berikut:

Tabel 5. Keluaran Skor VADER

Skor	Rentang	Makna
neg	0–1	Proporsi kata negatif
neu	0–1	Proporsi kata netral
pos	0–1	Proporsi kata positif
compound	-1 hingga +1	Skor sentimen keseluruhan (Hutto & Gilbert, 2014)

Penggunaan nilai *compound* direkomendasikan karena menggabungkan seluruh polaritas menjadi satu nilai stabil yang cocok untuk analisis dokumen berita.

Validitas Metodis

Pendekatan inset lexicon memiliki dua keunggulan utama: (1) transparansi analisis karena proses berbasis kamus dapat ditelusuri, dan (2) kemampuan adaptasi bahasa yang tinggi tanpa memerlukan proses pelatihan model. Namun, pendekatan ini tetap memiliki keterbatasan dalam memahami konteks, negasi implisit, atau struktur sintaksis kompleks sebagaimana dijelaskan dalam studi [15] karena itu, inset lexicon digunakan sebagai dasar untuk menghasilkan skor sentimen yang akurat sebelum diteruskan ke tahap klasifikasi lebih lanjut seperti rule-based atau model berbasis pembelajaran mesin.

2.7 VADER

VADER merupakan singkatan dari *Valence Aware Dictionary and sEntiment Reasoner*. Secara resmi, VADER didefinisikan sebagai sebuah alat analisis sentimen berbasis *lexicon* dan aturan, yang dirancang khusus untuk menangani ekspresi sentimen di media sosial seperti Twitter, Facebook, dan bentuk lainnya. Metode ini pertama kali diperkenalkan melalui sebuah publikasi ilmiah di *International Conference on Weblogs and Social Media (ICWSM)*.

VADER dibuat untuk menjawab tantangan analisis sentimen pada konten media sosial, yang umumnya berbentuk teks singkat, tidak baku, serta banyak menggunakan emotikon, bahasa gaul, dan singkatan. Karakteristik tersebut sulit diolah dengan leksikon konvensional

ataupun model *machine learning* yang membutuhkan data pelatihan dalam jumlah besar [16]. VADER didasari pada dua komponen utama, yaitu leksikon valensi dan aturan linguistik. Leksikon ini berisi kata dan simbol yang diberi nilai intensitas sentimen dari -4 hingga $+4$, sedangkan aturan linguistik membaca penekanan emosi melalui tanda baca, huruf kapital, negasi, kata penguat, dan konjungsi kontras. Model ini menggabungkan kemudahan pendekatan leksikal dengan kemampuan mengukur variasi kekuatan sentimen secara lebih akurat.

Sebagai metode berbasis aturan, VADER menggunakan lima aturan dan heuristik utama:

1. Tanda Baca (*Punctuation*): Keberadaan tanda seru (!) akan menaikkan nilai/skor sentimen sebesar 0,293.
2. Huruf Kapital (*Capitalization*): Jika kata bermuatan emosi muncul dengan huruf kapital, skor ditambah sebesar 0,733.
3. Pengubah Derajat (*Degree Modifiers*): Skor akan disesuaikan berdasarkan kata penguat seperti “*extremely*” atau “*marginally*”.
4. Konjungsi Kontrasif (*Contrastive Conjunction*): Kata “*but*” mengindikasikan adanya perubahan polaritas emosional dalam kalimat.
5. Penanganan Negasi (*Negation Handling*): Jika ditemukan bentuk negasi, skor akan dikalikan dengan $-0,74$.

Pada tahap akhir, nilai tersebut dinormalisasi ke kisaran -1 hingga 1 menggunakan rumus berikut, di mana parameter α umumnya diset atau bernilai 15:

$$S_{\text{compound}} = \frac{S_{\text{total}}}{\sqrt{S_{\text{total}}^2 + \alpha}}$$

Penelitian ini menggunakan *SentimentIntensityAnalyzer* dari NLTK untuk memperoleh skor sentimen berdasarkan VADER dan membuat kolom baru (*vader_sentiment_score*) [17].

3. RESULTS AND DISCUSSION

3.1 Pengumpulan Data

Pengumpulan data dilakukan melalui teknik *web scraping* pada situs CNBC Indonesia dengan kata kunci “MBG” dalam periode 1 Januari 2023 hingga 12 November 2025. Proses ini dilaksanakan menggunakan Python dengan memanfaatkan *library requests*, *BeautifulSoup*, *pandas*, *re*, dan *time*.

Tahap awal dilakukan dengan mengirimkan permintaan HTTP ke halaman pencarian CNBC Indonesia. Permintaan ini disertai *User-Agent* agar server mengenali akses sebagai permintaan dari browser sehingga menurunkan potensi penolakan. Setelah memperoleh respons yang valid, struktur HTML dari halaman pencarian diolah menggunakan *parser* untuk mengidentifikasi elemen-elemen yang memuat daftar berita.

Selanjutnya, setiap halaman pencarian diakses secara berurutan berdasarkan parameter tanggal dan nomor halaman (1–94). Dari setiap halaman, sistem mengekstraksi tautan berita

yang ditampilkan pada hasil pencarian. Tautan-tautan tersebut kemudian diakses kembali untuk memperoleh informasi lengkap dari masing-masing artikel.

Pada tahap ekstraksi detail berita, halaman artikel dibaca untuk memperoleh tiga komponen utama: judul berita, tanggal publikasi, dan isi artikel. Informasi judul dan tanggal diambil dari bagian skrip internal laman yang memuat metadata artikel, sedangkan isi berita diperoleh dengan mengumpulkan seluruh teks yang berada dalam elemen paragraf.


3.2 Analisis Sentimen - Adit

Setelah data berhasil diperoleh melalui proses web scraping, teks yang terkumpul kemudian dianalisis menggunakan pendekatan analisis sentimen dan terdistribusi ke dalam tiga kategori utama, yaitu sentimen negatif, netral, dan positif, hasil pemetaan awal ini memberikan gambaran mengenai kecenderungan opini dalam dataset. Untuk memperoleh skor sentimen yang lebih akurat pada konteks bahasa Indonesia, analisis kemudian dilanjutkan dengan menggunakan algoritma VADER yang telah diperluas menggunakan *InSet Lexicon*. Integrasi InSet ke dalam VADER memungkinkan sistem mengenali bobot sentimen kata-kata dalam bahasa Indonesia dengan lebih baik, sehingga empat skor utama *negative*, *neutral*, *positive*, dan *compound*. Skor numerik inilah yang selanjutnya digunakan sebagai input pada proses fuzzifikasi, sehingga penentuan sentimen tidak hanya bergantung pada batasan tegas, tetapi mempertimbangkan derajat keanggotaan yang lebih halus dan sensitif terhadap variasi dalam teks berita.

Berdasarkan hasil klasifikasi awal, distribusi sentimen menunjukkan bahwa kategori netral mendominasi dengan 740 artikel (65,66%), diikuti oleh sentimen positif sebanyak 235 artikel (20,85%), dan negatif sebanyak 152 artikel (13,48%). Perbandingan ini menunjukkan bahwa sebagian besar pemberitaan cenderung bersifat informatif dan tidak memuat opini emosional yang kuat. Distribusi ini kemudian dibandingkan kembali setelah melalui proses fuzzifikasi untuk melihat perubahan hasil klasifikasi yang lebih halus dan adaptif terhadap intensitas sentimen dalam teks, hasil distribusi seperti pada tabel dan gambar dibawah.

Tabel 6. Distribusi Awal Label Sentimen

Label	Artikel MBG
Positif	235
Netral	740
Negatif	152
Total	1127



Gambar 2. Distribusi Frekuensi Label Sentimen

3.3 Fuzzifikasi

Pada tahap awal, analisis sentimen dibangun dengan tiga variabel utama: positif, negatif, dan netral. Masing-masing variabel ini mewakili kecenderungan emosi dari suatu teks atau data numerik. Nilai input awal biasanya berupa angka antara 0 sampai 1, tetapi interpretasinya masih kasar. Oleh karena itu, setiap variabel input (positif, negatif, netral) direpresentasikan sebagai sebuah domain nilai kontinu:

$$x \in [0,1]$$

dengan increment 0.01, dimana ini memberikan presisi yang baik untuk perhitungan fuzzy. Ini adalah ruang nilai yang akan di-fuzzifikasi menjadi beberapa tingkat intensitas.

Selanjutnya, setiap variabel (positif, negatif, netral) dibagi menjadi tiga membership set:

1. Low (rendah)
2. Mid (sedang)
3. High (tinggi)

Secara matematis, tiap tingkat adalah sebuah *membership function* atau fungsi keanggotaan:

$$\mu_{\text{low}}(x), \mu_{\text{mid}}(x), \mu_{\text{high}}(x)$$

Fungsi ini menentukan seberapa besar nilai input masuk kategori tertentu.

Pengelompokan ini memungkinkan sistem memahami apakah suatu sentimen hanya sedikit cenderung positif, cukup positif, atau sangat positif. Begitu pula sebaliknya untuk negatif dan netral. Dengan adanya tingkatan ini, model tidak sekadar membuat keputusan biner, tetapi mempertimbangkan derajat intensitas dari setiap emosi.

Setelah itu analisis dilakukan pada setiap tingkat intensitas diberikan kurva keanggotaan fuzzy yang menggambarkan seberapa kuat nilai input termasuk ke kategori tertentu. Transisi antar kategori dibuat halus sehingga nilai input dapat memiliki keanggotaan pada lebih dari

satu tingkat secara bersamaan. Pendekatan ini meningkatkan fleksibilitas dalam membaca emosi yang ambigu atau berada di batas tengah. Berikut pemetaan derajat keanggotaan (*membership functions*):

a. Fungsi Keanggotaan Trapesium (*Trapezoidal Membership Function*)

Digunakan untuk kategori low dan high.


$$\mu_{\text{trap}}(x; a, b, c, d) = \begin{cases} 0, & x \leq a \\ \frac{x - a}{b - a}, & a < x \leq b \\ 1, & b < x \leq c \\ \frac{d - x}{d - c}, & c < x \leq d \\ 0, & x > d \end{cases}$$

Fungsi ini cocok untuk kategori intensitas rendah dan tinggi karena memiliki “area datar” yang mendefinisikan keanggotaan penuh. Pada penelitian ini digunakan *fuzz.trapmf* untuk menangkap kategori dengan plateau (rentang penuh). Berikut paramater yang digunakan:

1. Negatif

- a. `neg_low = fuzz.trapmf (x, [0.00, 0.00, 0.15, 0.35])`
- b. `neg_high = fuzz.trapmf (x, [0.55, 0.75, 1.00, 1.00])`

Nilai parameter ini disesuaikan agar fuzzy dapat bekerja dengan halus. Seperti pada *neg_low* jika rentang menjadi [0.00, 0.2], maka ini akan menyebabkan banyak teks negatif ringan yang akan hilang atau tidak terdeteksi. Jika batas menjadi [0.00, 0.5], maka akan menyebabkan informasi terlalu luas dan membingungkan. Ini juga berlaku untuk *neg_high* parameter tersebut dipilih agar informasi yang terdeteksi akan stabil.



Gambar 3. Membership Function Negative


Gambar tersebut menunjukkan fungsi keanggotaan trapesium fuzzy untuk *neg_low*, yang menggambarkan tingkat keanggotaan suatu nilai skor sentimen terhadap label “rendah/low”. Pada rentang skor 0 hingga 0,15, nilai keanggotaan bernilai 1, yang berarti seluruh nilai sentimen dalam interval ini dianggap sepenuhnya rendah. Setelah itu, pada interval 0,15 hingga 0,35, kurva menurun secara linear dari nilai 1 ke 0, menandakan bahwa semakin besar skor sentimen, semakin kecil tingkat keterkaitannya dengan kategori “Low”.

Di atas skor 0,35, nilai keanggotaan menjadi 0, yang berarti skor sentimen tersebut tidak lagi dikategorikan sebagai nilai negatif yang rendah.

2. Neutral

- $\text{neu_low} = \text{fuzz.trapmf}(x, [0.00, 0.00, 0.20, 0.40])$
- $\text{neu_high} = \text{fuzz.trapmf}(x, [0.70, 0.85, 1.00, 1.00])$

Ini adalah area ketika kalimat netral. Untuk *neu_low* adalah ketika kalimat hampir netral, sedangkan untuk *neu_high* adalah ketika kalimat masih meragukan jika dianggap positif, padahal tidak sepenuhnya benar. Oleh karena itu, nilai parameter ini disesuaikan agar informasi yang tertangkap atau terdeteksi tidak terlalu luas dan membingungkan.



Gambar 4. Membership Function Neutral

Gambar tersebut menampilkan fungsi keanggotaan trapesium fuzzy untuk kategori *neu_high*, yang menggambarkan tingkat keanggotaan suatu skor terhadap label “tinggi/high”. Pada rentang skor 0 hingga sekitar 0,70, nilai keanggotaan adalah 0, menunjukkan bahwa skor dalam interval tersebut tidak dianggap sebagai nilai neutral yang tinggi. Mulai dari skor 0,70 hingga 0,85, kurva meningkat secara linear dari 0 hingga 1, menandakan bahwa semakin besar skor, semakin tinggi tingkat keterkaitannya dengan kategori “High”. Setelah melewati skor 0,85 hingga 1, nilai keanggotaan tetap berada pada 1, yang berarti skor tersebut sepenuhnya memenuhi kategori *neu_high*.

3. Positif

- $\text{pos_low} = \text{fuzz.trapmf}(x, [0.00, 0.00, 0.15, 0.35])$
- $\text{pos_high} = \text{fuzz.trapmf}(x, [0.55, 0.75, 1.00, 1.00])$

Nilai parameter ini disesuaikan agar informasi yang tertangkap atau terdeteksi tidak terlalu luas dan membingungkan. Parameter *pos_low* dibuat simetris dengan *neg_low* agar sistem tetap stabil atau seimbang, begitu juga untuk *pos_high*.

b. Fungsi Keanggotaan Segitiga (*Triangular Membership Function*)

Umumnya dipakai untuk kategori mid (intensitas sedang).

$$\mu_{\text{tri}}(x; a, b, c) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a < x \leq b \\ \frac{c-x}{c-b}, & b < x \leq c \\ 0, & x > c \end{cases}$$

Fungsi ini menekankan nilai tengah sebagai keanggotaan tertinggi. Pada penelitian ini *fuzz.trimf* menandai kategori yang lebih terpusat di titik tengah. Namun, variabel netral memiliki rentang tengah yang lebih lebar, sehingga fungsi keanggotaannya cenderung:

1. lebih rapat di pusat (misalnya pusat di $x = 0.5$)
2. lebih meluas agar tidak cepat masuk ke kategori positif/negatif


Secara matematis tetap berbentuk *trapezoid/triangle*, tetapi dengan interval tengah b dan c lebih besar, misal:

$$\mu_{\text{neutral-mid}}(x) = \mu_{\text{tri}}(x; a, b, c), \text{ dengan interval } (b-a) \text{ dan } (c-b) \text{ diperbesar.}$$

Hal ini bertujuan agar model tidak mudah menganggap data sebagai positif atau negatif ketika nilainya sebenarnya tidak menunjukkan kecenderungan kuat. Dengan kata lain, netral berfungsi sebagai penyangga yang menjaga agar klasifikasi tidak menjadi terlalu terburu-buru dalam mengambil keputusan ekstrem. Berikut parameter yang digunakan:

1. Negatif
 - a. `neg_mid = fuzz.trimf(x, [0.25, 0.45, 0.65])`
2. Neutral
 - a. `neu_mid = fuzz.trimf(x, [0.30, 0.55, 0.80])`
3. Positif
 - a. `pos_mid = fuzz.trimf(x, [0.25, 0.45, 0.65])`


Nilai-nilai parameter tersebut disesuaikan agar model dapat bekerja dengan stabil dan tidak ada informasi tertangkap yang masih membingungkan atau meragukan.




Gambar 5. Membership Function Positive

Gambar tersebut menunjukkan fungsi keanggotaan segitiga fuzzy untuk kategori *pos_mid*, yang merepresentasikan tingkat keanggotaan nilai skor terhadap sentimen positif


tingkat menengah(*mid*). Pada rentang skor 0 hingga sekitar 0,25, nilai keanggotaan bernilai 0, sehingga skor pada interval ini tidak termasuk dalam kategori positif menengah. Mulai dari skor 0,25 hingga mencapai puncaknya pada 0,45, kurva meningkat secara linear dari 0 hingga 1, menandakan semakin kuat keterkaitannya dengan kategori *pos_mid*. Setelah titik puncak tersebut, kurva menurun kembali secara linear dari 1 ke 0 pada rentang 0,45 hingga 0,65, hingga akhirnya nilai keanggotaan kembali menjadi 0 untuk skor di atas 0,65, yang berarti skor tersebut tidak lagi dianggap sebagai sentimen positif tingkat menengah(*mid*).



Gambar 6. Membership Function Negative Rule Based



Gambar 7. Membership Function Neutral Rule Based



Gambar 8. Membership function Positive Rule Based

Setelah input diterjemahkan ke dalam kategori fuzzy, langkah berikutnya adalah menentukan bentuk keluaran (*output*) sentiment akhir. Namun pembagiannya dibuat lebih seimbang agar hasil akhir tidak terlalu ekstrem. Dengan cara membentuk fungsi keanggotaan fuzzy yang terdistribusi secara proporsional antara negatif, netral, dan positif. Dengan

menggunakan *trapmf* dan *trimf*, rentang nilai [0, 1] dengan increment 0.01, lalu diubah menjadi tingkat keanggotaan sentimen yang lebih halus sehingga model dapat menangkap variasi emosi secara gradual, bukan biner. Berikut parameternya:

$$1. \text{sentiment['negative']} = \text{fuzz.trapmf}(\text{sentiment_x}, [0.00, 0.00, 0.25, 0.45])$$

Parameter ini adalah parameter dalam fungsi keanggotaan trapesium fuzzy. Parameter ini disesuaikan agar sistem penilaian sentimen lebih seimbang dan tidak menghasilkan informasi yang membingungkan.

$$2. \text{sentiment['neutral']} = \text{fuzz.trimf}(\text{sentiment_x}, [0.35, 0.50, 0.65])$$

Parameter ini adalah parameter dalam fungsi keanggotaan segitiga fuzzy. Parameter ini disesuaikan agar sistem penilaian sentimen lebih seimbang dan tidak menghasilkan informasi yang membingungkan.

$$3. \text{sentiment['positive']} = \text{fuzz.trapmf}(\text{sentiment_x}, [0.55, 0.75, 1.00, 1.00])$$

Dengan demikian, ketika input hanya sedikit menunjukkan kecenderungan ke arah tertentu, hasil akhirnya tetap mempertimbangkan ketidakpastian tersebut. Sehingga menghasilkan output sentimen yang lebih realistis, stabil, serta mampu mencerminkan spektrum emosi secara proporsional dalam proses analisis sentimen berbasis fuzzy logic. Hasil akhir juga direpresentasikan sebagai himpunan fuzzy:

$\text{sentiment} = \{\text{negative}, \text{neutral}, \text{positive}\}$, dimana masing-masing memiliki fungsi:

$$\mu_{\text{neg}}(y), \mu_{\text{neu}}(y), \mu_{\text{pos}}(y)$$

Fungsi keluaran ini dibuat seimbang agar sistem tidak menghasilkan putusan ekstrem. Secara matematis tetap menggunakan fungsi trapezoid/triangle yang sama seperti di atas.

3.4 Rule Based

Metode rule-based diterapkan pada hasil *web scraping* dengan tujuan mengklasifikasikan sentimen berdasarkan keberadaan kata kunci bermakna positif, negatif, atau netral dalam teks berita. Pendekatan ini mengikuti prinsip sederhana: apabila teks mengandung kata kunci bernada positif, maka dipetakan ke kelas *positive*; jika mengandung kata negatif, maka diklasifikasikan sebagai *negative*; dan apabila tidak terdapat dominasi salah satu polaritas atau teks cenderung informatif, maka ditempatkan pada kategori *neutral*. Pola seperti ini lazim digunakan dalam rule-based sentiment analysis pada teks media [18].

Kata kunci yang digunakan diturunkan dari kamus sentimen dasar, misalnya:

- Positive keywords: meningkat, naik, optimis, untung, ekspansi
- Negative keywords: turun, rugi, anjlok, gagal, tekanan
- Neutral keywords: laporan, umumkan, data, perusahaan, rilis

Proses klasifikasi sentimen berbasis rule-based bekerja mengikuti alur yang telah dirumuskan dalam diagram pada bagian metode, dimulai dari pendeteksian kata kunci pada teks yang telah dibersihkan hingga pemetaan akhir ke kelas sentimen. Pada tahap awal,

sistem mengekstraksi setiap kata dalam cleaned text dan membandingkannya dengan daftar kata kunci yang telah ditentukan untuk polaritas positif, negatif, dan netral. Ketika sebuah kata ditemukan berada dalam kelompok positif, sistem mengarahkan alur keputusan ke cabang aturan positif. Sebaliknya, apabila kata negatif muncul, alur berpindah menuju aturan negatif. Jika tidak terdapat indikasi dominan dari kedua polaritas tersebut, maka alur diarahkan ke aturan netral sesuai logika pada diagram alir.

Penerapan alur tersebut dapat diamati dari lima contoh data yang dianalisis. Kalimat pertama, misalnya, mengandung kata “meningkat” yang berada dalam daftar kata positif. Sesuai diagram alir, deteksi ini membuat sistem melewati cabang positif dan menghasilkan keluaran “Positive.” Berbeda dengan itu, contoh kedua memuat kata “tekanan” dan “memburuk” yang masuk kategori negatif, sehingga alur langsung mengarah pada keputusan “Negative.” Contoh ketiga tidak menunjukkan adanya kata bermuatan sentimen; alurnya berhenti pada jalur netral dalam diagram dan menghasilkan keluaran “Neutral.” Kalimat keempat menampilkan dua informasi (“turun” dan “stabil”), namun karena diagram alir mengutamakan pendeteksian kata negatif sebagai bukti kuat polaritas, sistem tetap mengklasifikasikannya sebagai “Negative.” Pada contoh kelima, keberadaan kata “ekspansi” mengarahkan proses ke jalur positif sehingga klasifikasi akhirnya “Positive.” Aliran keputusan ini menunjukkan bahwa sistem rule-based lebih menekankan keberadaan kata kunci polaritas utama dibanding struktur kalimat secara keseluruhan.

Hasil tersebut menegaskan bahwa rule-based mampu menangkap sentimen eksplisit dengan baik, terutama pada pola kalimat yang secara langsung menyatakan perubahan, pergerakan, atau penilaian. Namun, kinerja sistem menunjukkan keterbatasan pada konteks yang lebih halus atau ambigu. Misalnya, sistem belum mampu membedakan antara “turun sementara” dan “turun tajam,” atau mendeteksi perubahan makna akibat negasi seperti “tidak meningkat.” Dengan demikian, alur keputusan sederhana yang digunakan rule-based hanya efektif pada teks berstruktur langsung dan kurang efisien ketika diterapkan pada berita ekonomi yang memiliki nuansa semantik lebih kompleks, sebagaimana ditegaskan juga oleh studi lexicon-based kontemporer (Mahajani et al., n.d.), yang menyatakan bahwa sistem berbasis aturan cenderung mengalami penurunan akurasi ketika menghadapi variasi diksi dan ekspresi implisit.

Secara keseluruhan, implementasi rule-based memberikan gambaran yang transparan dan mudah ditelusuri mengenai bagaimana suatu teks diarahkan menuju keputusan akhir. Namun, sifat linear dari alur rule-based menjadikan sistem ini memiliki kecenderungan menghasilkan kelas netral secara dominan ketika teks lebih bersifat informatif atau deskriptif. Kondisi ini secara tidak langsung memengaruhi keseimbangan kelas serta menurunkan efektivitas apabila digunakan sebagai metode utama. Rule-based dengan demikian lebih tepat diposisikan sebagai baseline interpretatif, sementara analisis sentimen berbasis model kontekstual diperlukan untuk menangani struktur bahasa yang lebih dinamis.

Untuk memperjelas pola hasil klasifikasi, berikut representasi tematik berdasarkan lima sampel data:

Tabel 7. Visualisasi Hasil Rule Based

Tema Berita	Contoh Kata Kunci	Keputusan Rule-Based	Pola Alur yang Tampak
Kinerja meningkat	meningkat	Positive	Alur langsung menuju cabang positif setelah kata kunci terdeteksi
Tekanan pasar	tekanan, memburuk	Negative	Sistem berhenti pada cabang negatif tanpa mempertimbangkan konteks tambahan
Rilis informasi	rilis, data	Neutral	Tidak ada polaritas → alur jatuh ke jalur netral
Pergerakan harga	turun	Negative	Deteksi kata negatif mendominasi alur meskipun terdapat informasi stabilisasi
Ekspansi bisnis	ekspansi	Positive	Kata positif mengarahkan sistem ke keputusan positif secara langsung

Visualisasi ini memperlihatkan bahwa alur rule-based bekerja secara deterministik: keberadaan kata kunci pertama yang memiliki polaritas kuat akan langsung menuntun alur pada keputusan sentimen final.

Tabel berikut merangkum perbedaan mendasar antara pendekatan rule-based yang digunakan dalam penelitian ini dan pendekatan berbasis transformer seperti IndoBERT.

Tabel 8. Perbandingan Rule-Based vs Model Berbasis Transformer

Aspek	Rule-Based (Penelitian Ini)	Model Transformer (IndoBERT dkk.)
Mekanisme dasar	Pencocokan kata kunci	Representasi kontekstual berbasis attention
Kemampuan memahami konteks	Sangat terbatas	Tinggi, memahami relasi kata dan negasi
Ketergantungan pada kamus	Sangat tinggi	Rendah, belajar dari korpus besar
Sensitivitas terhadap variasi diksi	Tinggi (mudah salah)	Rendah (mampu generalisasi)
Deteksi sentimen implisit	Hampir tidak ada	Mampu menangkap makna tersirat
Transparansi	Sangat tinggi (aturan jelas)	Lebih rendah tetapi lebih akurat

Cocok untuk	Baseline, data eksplisit	Analisis mendalam, teks kompleks
-------------	--------------------------	----------------------------------

Tabel komparatif ini menegaskan bahwa meskipun rule-based memberikan transparansi alur keputusan, pendekatan tersebut tidak mampu menangani kompleksitas bahasa jurnalistik secara memadai. Model berbasis transformer lebih unggul dalam memahami konteks semantik, menyelesaikan ambiguitas, dan memberikan klasifikasi yang lebih stabil pada data skala besar.

Lima contoh data digunakan untuk menunjukkan bagaimana aturan diterapkan.

Tabel 9. Penerapan Rule-Based pada Lima Contoh Data Berita

Original Text	Cleaned Text	Detected Keyword	Rule-Based Classification Output
“Saham MBG meningkat setelah laporan kinerja kuartal ketiga dirilis.”	saham mbg meningkat setelah laporan kinerja kuartal ketiga dirilis	meningkat (positive)	Positive
“MBG menghadapi tekanan pasar akibat sentimen global yang memburuk.”	mbg menghadapi tekanan pasar akibat sentimen global memburuk	tekanan, memburuk (negative)	Negative
“Perusahaan MBG merilis data penjualan rutin tanpa perubahan signifikan.”	perusahaan mbg rilis data penjualan rutin tanpa perubahan signifikan	rilis, data (neutral)	Neutral
“Harga saham MBG turun tipis di awal perdagangan namun kembali stabil.”	harga saham mbg turun tipis awal perdagangan namun kembali stabil	turun (negative)	Negative
“MBG mengumumkan ekspansi baru ke sektor energi terbarukan.”	mbg umumkan ekspansi baru sektor energi terbarukan	ekspansi (positive)	Positive

3.5 Inferensi Mamdani

Implementasi metode inferensi Mamdani dilakukan melalui pemanfaatan modul *scikit-fuzzy*, khususnya *skfuzzy.control*, yang menyediakan kerangka sistem pengambilan keputusan berbasis aturan. Variabel input berupa skor sentimen VADER (*compound*) yang terfuzzifikasi ke dalam tiga himpunan fuzzy linguistik utama, yaitu negatif, netral, dan positif, masing-masing direpresentasikan melalui fungsi keanggotaan berbentuk segitiga dan trapesium [19].

Pada metode Mamdani, proses inferensi dilakukan dengan menggabungkan kontribusi dari seluruh aturan fuzzy melalui operasi implikasi dan agregasi. Misalkan terdapat himpunan aturan berbentuk umum:

$$R_k: \text{JIKA } x \text{ adalah } A_k \text{ MAKA } y \text{ adalah } B_k, \text{ dengan } k = 1, 2, \dots, n$$

dengan:

- A_k = himpunan fuzzy input (negatif, netral, positif),
- B_k = himpunan fuzzy output dengan kategori yang sama,
- $\mu_{A_k}(x_0)$ = derajat keanggotaan input aktual x_0 terhadap himpunan A_k .

1. Implikasi (Operator Min)

Untuk setiap aturan, derajat aktivasi dihitung sebagai:

$$\alpha_k = \mu_{A_k}(x_0)$$

Lalu fungsi keanggotaan output untuk aturan ke-k dimodifikasi dengan operator minimum sebagai:

$$\mu'_{B_k}(y) = \min\{\alpha_k, \mu_{B_k}(y)\}$$

Ini menghasilkan kurva output terpotong (*clipped fuzzy set*) untuk setiap aturan. Proses ini digunakan untuk memotong konsekuen aturan berdasarkan aktivasi input.


2. Agregasi (Operator Max)

Seluruh output aturan yang telah diimplikasikan kemudian digabungkan menggunakan operator maksimum:

$$\mu_{B_k}(y) = \max_k (\mu'_{B_k}(y))$$

Hasil dari kedua proses di atas adalah himpunan fuzzy komposit yang mewakili kontribusi kolektif dari aturan negatif, netral, dan positif berdasarkan nilai input.

Berikut visualisasi proses inferensi.



Gambar 9. inferensi Mamdani

3.6 Proses Defuzzifikasi

Pada bagian sebelumnya, telah dilakukan fuzzifikasi pada analisis sentimen, selanjutnya akan dilakukan defuzzifikasi. Setiap data masukan memiliki tiga nilai: kecenderungan positif, negatif, dan netral. Ketiganya diasumsikan bernilai real:

$$\text{pos, neg, neu} \in [0,1]$$

Nilai-nilai ini menjadi input awal untuk proses inferensi fuzzy, yaitu menentukan derajat keanggotaan masing-masing pada himpunan fuzzy yang telah dibuat. Fungsi *predict_sentiment_improved()* bekerja dengan mengkonversi nilai fuzzy *pos*, *neg*, dan *neu* pada setiap baris data menjadi label sentimen melalui proses inferensi fuzzy yang lebih stabil. Selanjutnya, sistem fuzzy menggunakan aturan-aturan (rules) yang menghubungkan input dengan output. Proses inferensinya mengikuti prinsip:

$$\mu_{\text{output}}(y) = f(\mu_{\text{pos}}(x), \mu_{\text{neg}}(x), \mu_{\text{neu}}(x))$$

di mana fungsi f mengkombinasikan aturan fuzzy berbasis operator logika fuzzy, seperti:

- minimum untuk AND:

$$\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$$

- maximum untuk OR:

$$\mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$$

Operator-operator tersebut digunakan untuk menentukan kekuatan aturan fuzzy berdasarkan derajat keanggotaan input. Tidak ada keputusan tunggal yang kaku, semua dihitung berdasarkan intensitas masing-masing input.

Setiap iterasi dimulai dengan me-reset simulasi agar tidak ada residu perhitungan sebelumnya, kemudian memasukkan nilai input dan menjalankan proses fuzzy dari tahap fuzzification hingga defuzzification untuk menghasilkan skor crisp antara [0, 1]. Jika terjadi

error, misalnya nilai kosong atau tidak valid, fungsi memberikan skor *fallback* 0.5 yang mewakili kondisi netral paling aman. Setelah inferensi menghasilkan himpunan fuzzy untuk output. Hasil fuzzy yang masih berupa kurva harus diubah menjadi angka, sistem akan mengubahnya menjadi nilai tunggal (*crisp value*). Biasanya digunakan metode *centroid*, yaitu:

$$y^* = \frac{\int y \mu_{\text{sentiment}}(y) dy}{\int \mu_{\text{sentiment}}(y) dy}$$

Nilai $y^* \in [0,1]$ inilah skor sentimen fuzzy yang akhirnya dianalisis.

Setelah skor fuzzy diperoleh, interpretasi kategori sentimen dilakukan melalui pembatasan nilai (*threshold*). Secara matematis:

$$\text{label}(y^*) = \begin{cases} \text{negatif}, & \text{jika } y^* < t_1 \\ \text{netral}, & \text{jika } t_1 \leq y^* < t_2 \\ \text{positif}, & \text{jika } y^* \geq t_2 \end{cases}$$

Pada sistem ini, ambang batasnya adalah:

- $t_1 = 0.40$
- $t_2 = 0.63$

Penambahan threshold ini adalah bentuk *post-processing* untuk menyeimbangkan distribusi hasil fuzzy agar tidak terlalu condong ke kategori tertentu. Selanjutnya, proses klasifikasi dilakukan terhadap semua data secara berulang. Setiap baris data diproses satu per satu sehingga menghasilkan dua keluaran. Secara konseptual:

$$\text{Prediksi}(i) = \text{label}(y_i^*)$$

dan

$$y_i^* = \text{Skor fuzzy hasil defuzzifikasi untuk data ke-}i$$


Sehingga, diperoleh hasil akhirnya berupa label sentimen dan skor fuzzy yang memberikan kedalaman informasi.

3.7 Hasil Klasifikasi

Untuk memperoleh gambaran performa model, dilakukan analisis metrik evaluasi menggunakan confusion matrix dan classification report. Metrik yang digunakan meliputi precision, recall, f1-score, dan tingkat akurasi keseluruhan, yang ada pada tabel dibawah.

Tabel 10. Metrik Evaluasi

Label	Precision	Recall	F1-score	Support
Negatif	0.32	0.10	0.15	152
Netral	0.61	0.71	0.66	740
Positif	0.13	0.12	0.13	235



Gambar 10. Confusion Matrix

Dapat dilihat pada tabel .. dan gambar .., bahwa perbedaan cukup mencolok antara kedua metrik tersebut menandakan bahwa model bekerja sangat baik pada kelas dominan, yaitu kelas netral, namun memiliki kinerja yang jauh lebih rendah pada kelas minoritas seperti negatif dan positif. Kondisi ini umum terjadi pada data ulasan dengan distribusi kelas yang tidak seimbang.

Tabel 11. Akurasi pada data MBG menggunakan metode Fuzzy

Data	F1 Macro	F1 Micro
MBG	0.31	0.51

Dari tabel diatas, Nilai F1-Micro sebesar 0.51 menunjukkan bahwa secara keseluruhan model memiliki kemampuan yang cukup baik dalam mengklasifikasikan data dengan benar. Karena perhitungan F1-Micro didasarkan pada total prediksi benar dari seluruh kelas, model bekerja efektif pada kelas yang jumlah datanya besar, yaitu kelas netral yang memang mendominasi distribusi data. Sebaliknya, F1-Macro hanya mencapai 0.31, yang berarti bahwa ketika performa dievaluasi secara seimbang untuk setiap kelas (negatif, netral, positif), kualitas model menurun signifikan. F1-Macro tidak mempertimbangkan jumlah sampel tiap kelas, sehingga performa model dalam mendeteksi kelas minoritas terlihat jauh lebih rendah.

Perbedaan yang besar antara F1-Micro dan F1-Macro mengindikasikan terjadinya ketidakseimbangan kelas dan ketergantungan model terhadap kelas dominan. Temuan ini penting karena memberikan gambaran bahwa meskipun model tampak memiliki performa baik secara keseluruhan, kemampuan membedakan polaritas ekstrem seperti positif dan negatif masih terbatas.


Selain itu, analisis distribusi label hasil klasifikasi fuzzy menunjukkan bahwa model menghasilkan proporsi prediksi yang sangat berat ke kelas netral. Dari total data, sebesar 76.57% sampel dipetakan sebagai netral, sementara prediksi untuk kelas positif dan negatif

mencapai 19.25% dan 4.17%. Jika dibandingkan dengan distribusi asli 65.66% netral, 20.85% positif, dan 13.49% negatif terlihat bahwa fuzzy membentuk ketidakseimbangan tetapi tidak terlalu ekstrem. Kondisi ini terjadi karena mekanisme fuzzy cenderung menghasilkan nilai keluaran yang berada pada rentang tengah, sehingga banyak sampel didorong ke kategori netral. Dampaknya, kemampuan model dalam membedakan sentiment positif dan negatif menjadi terbatas dan tercermin pada rendahnya F1-score kedua kelas tersebut.

Secara keseluruhan, temuan ini menunjukkan bahwa pendekatan fuzzy mampu memberikan representasi linguistik yang lebih fleksibel dan menangani ketidakpastian pada data teks, performanya tetap sangat dipengaruhi oleh bentuk fungsi keanggotaan dan aturan inferensi yang digunakan. Imbalance yang tercipta pada hasil klasifikasi menunjukkan perlunya penyetelan ulang parameter fuzzy, khususnya pada batasan antar kategori dan desain membership function, agar distribusi prediksi lebih seimbang dan kemampuan membedakan polaritas yang lebih ekstrem dapat meningkat. Dengan demikian, pendekatan fuzzy tetap memiliki potensi besar dalam analisis sentimen, namun memerlukan optimalisasi lebih lanjut agar kinerjanya dapat sejalan dengan karakteristik distribusi data yang sesungguhnya.

Tabel 12. Label Distribusi perbandingan data asli dan fuzzy

Label	Data Asli	Data Asli %	Data Fuzzy	Data Fuzzy %
Netral	740	65.66%	863	76.57%
Positif	235	20.85%	217	19.25%
Negatif	152	13.48%	47	4.17%



Gambar 11. Distribusi Prediksi Model

4. CONCLUSION

Penelitian ini menerapkan sistem inferensi Mamdani untuk analisis sentimen berita MBG melalui integrasi VADER dan InSet Lexicon, dimulai dari proses scraping, preprocessing, perhitungan skor sentimen, fuzzifikasi, rule-based inference, hingga defuzzifikasi. Hasil evaluasi menunjukkan performa yang belum optimal, dengan F1-Micro sebesar 0.51 dan F1-Macro sebesar 0.31, serta kecenderungan prediksi yang berat ke kelas netral (76.57%), sehingga sentimen positif dan negatif memiliki F1-score rendah (0.13 dan 0.15). Keterbatasan utama berasal dari InSet Lexicon yang belum sepenuhnya sesuai dengan konteks linguistik pemberitaan ekonomi Indonesia, sehingga skor polaritas yang dihasilkan cenderung lemah dan tidak cukup kuat untuk mengaktifkan aturan fuzzy secara efektif. Meskipun rule base pada sistem inferensi Mamdani terbukti dapat digunakan dan mampu memberikan keputusan sentimen yang lebih gradual, mekanisme ini tetap dipengaruhi oleh kualitas input lexicon, sehingga beberapa aturan tidak teraktivasi dengan optimal. Dengan demikian, penelitian ini menegaskan bahwa peningkatan akurasi dapat dicapai melalui

pengembangan lexicon khusus domain ekonomi, penyesuaian bobot polaritas, serta perluasan aturan fuzzy untuk menangani variasi polaritas yang lebih kompleks.

REFERENCES

- [1] S. Vashishtha and S. Susan, "Fuzzy rule based unsupervised sentiment analysis from social media posts," vol. 138, 2019, doi: 10.1016/j.eswa.2019.112834.
- [2] E. P. Wijaya and M. H. Rifqo, "Jurnal Informatika : Jurnal pengembangan IT Analisis Sentimen terhadap Lembaga Danantara Menggunakan Evolutionary Fuzzy Rule-Based Classification System," vol. 10, no. 4, pp. 967–977, 2025, doi: 10.30591/jpit.v10i4.8845.
- [3] M. H. Hasan, I. A. Aziz, J. Jaafar, L. A. B. Rahim, J. Mabor, and A. Manyiel, "A Comparative Study of Mamdani and Sugeno Fuzzy Models for Quality of Web Services Monitoring," vol. 8, no. 9, 2017.
- [4] L. A. Zadeh, I. Introduction, and U. S. Navy, "Fuzzy Sets * -," vol. 353, pp. 338–353, 1965.
- [5] Timothy J. Ross, "Properties of Membership Functions, Fuzzification, and Defuzzification," in *Fuzzy Logic with Engineering Applications*, 2010, pp. 89–116. doi: 10.1002/9781119994374.
- [6] D. S. Naidu and C. T. Sun, "Neuro-Fuzzy and Soft Computing—A Computational Approach to Learning and Machine Intelligence," vol. 42, no. 10, pp. 1482–1484, 1997.
- [7] K. Pancerz, M. Chylą, S. Augustynowicz, and J. Gomula, "Experiments with with Fuzzification Fuzzification of of MMPI MMPI Profiles Profiles for for the the Classification Task Classification Task," *Procedia Comput. Sci.*, vol. 176, pp. 3486–3495, 2020, doi: 10.1016/j.procs.2020.09.048.
- [8] M. Taboada, J. Brooke, and K. Voll, "Lexicon-Based Methods for Sentiment Analysis," no. August 2010, 2011.
- [9] A. M. V. D. V. Id and E. Bleich, "The advantages of lexicon-based sentiment analysis in an age of machine learning," pp. 1–19, 2025, doi: 10.1371/journal.pone.0313092.
- [10] K. Pujaru, S. Adak, T. K. Kar, S. Patra, and S. Jana, "A Mamdani fuzzy inference system with trapezoidal membership functions for investigating fishery production ☆," *Decis. Anal. J.*, vol. 11, no. May, p. 100481, 2024, doi: 10.1016/j.dajour.2024.100481.
- [11] E. Desvania, "Traffic Lights Analysis and Simulation Using Fuzzy Inference System of Mamdani on Three-Signaled Intersections .," *Procedia Comput. Sci.*, vol. 179, pp. 268–280, 2021, doi: 10.1016/j.procs.2021.01.006.
- [12] T. Takagi and M. Sugeno, "Fuzzy Identification of Systems and Its Applications to Modeling and Control," *IEEE Trans. Syst. Man. Cybern.*, vol. SMC-15, no. 1, pp. 116–132, 1985, doi: 10.1109/TSMC.1985.6313399.
- [13] V. N. Juli, A. Jl, R. Madya, G. Anyar, K. Gn, and J. Timur, "Perbandingan Performa Labeling Lexicon InSet dan VADER pada Analisa Sentimen Rohingya di Aplikasi X dengan SVM Muhammad Fernanda Naufal Fathoni Eva Yulia Puspaningrum

Andreas Nugroho Sihananto menghasilkan F1 sebesar 80 %. Penelitian lain dilakukan (Muhammadi et al ., 2022) dengan VADER sehingga menjadikan peneliti tertarik membuat perbandingan kombinasi lexicon InSet dan VADER dengan SVM pada analisa sentimen Rohingya sosial media X untuk mengetahui manakah performa yang lebih baik .,” vol. 1, no. 3, 2024.

- [14] Z. M. Michelle and K. Hanna, “Scoping natural language processing in Indonesian and Malay for education applications,” 2020.
- [15] Paschenko, K. Bochenina, and E. Kotelnikov, “Lexicon-based Methods vs. BERT for Text Sentiment Analysis,” vol. 95.
- [16] F. Valilai, “Agile Product Development by Prediction of Consumers ’ Agile Product by Prediction Consumers ’ Behaviour ; using Development Neurobehavioral and Social of Media Sentiment Behaviour ; using Neurobehavioral and Social Media Sentiment Analysis Approaches Ana,” *Procedia Comput. Sci.*, vol. 232, no. 2023, pp. 1683–1693, 2024, doi: 10.1016/j.procs.2024.01.166.
- [17] X. Luo, “Sentiment Analysis with VADER and LM Using Linear Regression for Stock Market Prediction,” no. Ecai 2024, pp. 33–38, 2025, doi: 10.5220/0013205600004568.
- [18] I. Cero, J. Luo, and J. Michael, “Lexicon - Based Sentiment Analysis in Behavioral Research,” *Perspect. Behav. Sci.*, vol. 47, no. 1, pp. 283–310, 2024, doi: 10.1007/s40614-023-00394-x.
- [19] D. Pemilihan, P. Mahasiswa, and U. Tugas, “PENGUNAAN METODE FUZZY INFERENCE SYSTEM (FIS) MAMDANI DALAM PEMILIHAN PEMINATAN MAHASISWA UNTUK TUGAS AKHIR Yulmaini,” vol. 15, no. 1, 2015.